

# **Inférence statistique**

## **Cours 2 : Inférence paramétrique**

Michal W. Urdanivia\*

\*UGA, Faculté d'Économie, GAEL,  
e-mail : [michal.wong-urdanivia@univ-grenoble-alpes.fr](mailto:michal.wong-urdanivia@univ-grenoble-alpes.fr)

14 septembre 2022

1. Modèle statistique

2. Identification

3. Estimation des paramètres

4. Intervalles de confiance

# Plan

1. Modèle statistique

2. Identification

3. Estimation des paramètres

4. Intervalles de confiance

# **1. Modèle statistique**

# 1. Modèle statistique

- On considère le résultat observé d'une expérience statistique qui est un échantillon  $X_1, X_2, \dots, X_n$  de  $n$  v.a. i.i.d. sur un espace mesurable  $(\mathcal{E}, \mathcal{F})$ , avec typiquement  $\mathcal{E} \subseteq \mathbb{R}$ , et de distribution commune notée  $P$ .
- Définition formelle : un **modèle statistique** associé à cette expérience statistique est un triplet :

$$(\mathcal{E}, \mathcal{F}, (P_\theta)_{\theta \in \Theta}),$$

où :

- $(\mathcal{E}, \mathcal{F})$  est l'espace mesurable des observations ;
- $(P_\theta)_{\theta \in \Theta}$  est une famille de mesures de probabilité sur  $(\mathcal{E}, \mathcal{F})$  ;
- $\Theta$  est appelé l'**ensemble des paramètres**.

# 1. Modèle statistique

- Généralement il sera supposé que le modèle est **correctement spécifié**, i.e., défini tel que  $P = P_{\theta}$ , pour un  $\theta \in \Theta$ .
- Ce paramètre en particulier est appelé **vrai paramètre**, et il est inconnu : le but de l'expérience statistique est de l'estimer.
- On supposera aussi que  $\Theta \subseteq \mathbb{R}^d$  pour  $d \geq 1$ . On parle alors de **modèle paramétrique**.

# 1. Modèle statistique

## ● Exemples :

1. Pour  $n$  tirages de Bernoulli :

$$\left( \{0, 1\}, \mathcal{P}(\{0, 1\}), (Ber(p))_{p \in (0,1)} \right)$$

2. Si  $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} Exp(\lambda)$ , pour un  $\lambda > 0$  inconnu :

$$\left( \mathbb{R}_+^*, \mathcal{B}(\mathbb{R}_+^*), (Exp(\lambda))_{\lambda > 0} \right).$$

3. Si  $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} Poiss(\lambda)$ , pour un  $\lambda > 0$  inconnu :

$$\left( \mathbb{N}, \mathcal{P}(\mathbb{N}), (Poiss(\lambda))_{\lambda > 0} \right).$$

# 1. Modèle statistique

4. Si  $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \mathcal{N}(\mu, \sigma^2)$ , pour un  $\mu \in \mathbb{R}$  inconnu et  $\sigma^2 > 0$  :

$$\left( \mathbb{R}, \mathcal{B}(\mathbb{R}), \left( \mathcal{N}(\mu, \sigma^2) \right)_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*} \right).$$



# Plan

1. Modèle statistique

**2. Identification**

3. Estimation des paramètres

4. Intervalles de confiance

## **2. Identification**

## 2. Identification

- Le paramètre  $\theta$  est qualifié d'**identifié** ssi l'application  $\theta \in \Theta \mapsto P_\theta$  est injective, i.e.,

$$\theta \neq \theta' \Rightarrow P_\theta \neq P_{\theta'}$$

1. Dans tous les exemples précédents le paramètre était identifié.
2. Si  $X_i = \mathbf{1}(U_i \geq 0)$ , où  $U_1, U_2, \dots, U_n \stackrel{i.i.d.}{\sim} \mathcal{N}(\mu, \sigma^2)$ , pour un  $\mu \in \mathbb{R}$  et  $\sigma^2 > 0$ , tous les deux inobservés :  $\mu$  et  $\sigma^2$  ne sont pas identifiés. Néanmoins  $\mu/\sigma$  l'est.

# Plan

1. Modèle statistique

2. Identification

**3. Estimation des paramètres**

4. Intervalles de confiance

### **3. Estimation des paramètres**

### 3. Estimation des paramètres

- **Idée** : étant donné un échantillon  $X_1, X_2, \dots, X_n$  et un modèle statistique  $(\mathcal{E}, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ , on veut estimer le paramètre  $\theta$ .
- **Définitions** :
  - **Statistique** : toute fonction mesurable de l'échantillon, e.g.,  $\bar{X}_n$ ,  $\max_i X_i$ ,  $X_1 + \log(1 + |X_n|)$ , variance empirique, etc, ...
  - **Estimateur** de  $\theta$  : toute statistique dont l'expression ne dépend pas de  $\theta$ .
  - Un estimateur  $\hat{\theta}$  de  $\theta$  est **faiblement consistant/convergent** ssi :

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (\text{par rapport à } P_\theta).$$

**Remarque** : lorsque la convergence est presque sûre (i.e., " $\xrightarrow{P.S.}$ " à la place de " $\xrightarrow{P}$ "), l'estimateur est **fortement consistant/convergent**.

### 3. Estimation des paramètres

- **Biais** d'un estimateur  $\hat{\theta}_n$  de  $\theta$  :

$$E(\hat{\theta}_n) - \theta.$$

- **Risque(ou risque quadratique)** d'un estimateur  $\hat{\theta}_n$  :

$$E\left(|\hat{\theta}_n - \theta|^2\right).$$

**Remarque** : si  $\Theta \subseteq \mathbb{R}$ ,

$$\text{Risque quadratique} = \text{Biais}^2 + \text{Variance}.$$

# Plan

1. Modèle statistique

2. Identification

3. Estimation des paramètres

4. Intervalles de confiance



## **4. Intervalles de confiance**

## 4. Intervalles de confiance

- Soit un modèle statistique  $(\mathcal{E}, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$  sur les observation  $X_1, X_2, \dots, X_n$ , et supposons  $\Theta \subseteq \mathbb{R}$ .
- **Définitions** : pour  $\alpha \in (0, 1)$ .
  - **Intervalle de confiance(C.I.) de niveau  $1 - \alpha$**  pour  $\theta$  : tout intervalle aléatoire(i.e., dépendant de  $X_1, X_2, \dots, X_n$ )  $IC$  dont les bornes ne dépendent pas de  $\theta$  et tel que :

$$P(IC \ni \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta.$$

- **Intervalle de confiance(C.I.) de niveau asymptotique  $1 - \alpha$**  pour  $\theta$  : tout intervalle aléatoire  $IC$  dont les bornes ne dépendent pas de  $\theta$  et tel que :

$$\lim_{n \rightarrow \infty} P_\theta(IC \ni \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta.$$

## 4. Intervalles de confiance

- **Exemple** : Soit  $X_1, X_2, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Ber}(p)$ , pour un  $p \in (0, 1)$  inconnu.
  - LGN : la moyenne empirique  $\bar{X}_n$  est un estimateur fortement consistant de  $p$ .
  - Soit  $t_\alpha$  le quantile d'ordre  $(1 - \frac{\alpha}{2})$  de la loi  $\mathcal{N}(0, 1)$  et :

$$IC = \left[ \bar{X}_n - \frac{t_\alpha \sqrt{p(1-p)}}{\sqrt{n}}; \bar{X}_n + \frac{t_\alpha \sqrt{p(1-p)}}{\sqrt{n}} \right].$$

- TCL :

$$\lim_{n \rightarrow \infty} P_p(IC \ni p) = 1 - \alpha, \quad \forall p \in (0, 1).$$

- **Problème** :  $IC$  dépend de  $p$  !

## 4. Intervalles de confiance

- **Deux solutions :**

- (i) Remplacer  $p(1 - p)$  par  $1/4$  (car  $p(1 - p) \leq 1/4$ ).
- (ii) Remplacer  $p$  par  $\bar{X}_n$  dans  $IC$  et utiliser le théorème de Slutsky.